

Un Sistema Jerárquico de Estimación de Anomalías a Vida Útil Residual con Tiempo de Adelanto Cuantificado para el Mantenimiento Predictivo de Motores de Aeronaves

Rafael Pecino Bonilla^{a,*}, Jesús Gil^a

^aUniversidad Alfonso X El Sabio (UAX), Máster en Inteligencia Artificial, Avenida de la Universidad 1, Villanueva de la Cañada, 28691, Madrid, España

Abstract

El mantenimiento predictivo de motores de aeronaves requiere tanto la detección temprana de anomalías como una estimación precisa de la vida útil residual (RUL, por sus siglas en inglés). Los enfoques basados en datos existentes tratan estas tareas por separado, proporcionando bien indicadores de anomalía ventana a ventana o bien un único valor de RUL, pero raramente una señal operacional cuantificada que las vincule. Proponemos un sistema jerárquico en el que un autoencoder variacional convolucional unidimensional (Conv1D-VAE) actúa como compuerta cuantificada: cuando el error de reconstrucción supera un umbral calibrado bajo una regla de persistencia, se invoca un regresor profundo de RUL (ya sea CNN+LSTM o Transformer, evaluados como alternativas y no como conjunto), y su salida se informa con incertidumbre epistémica estimada mediante Monte Carlo Dropout. Evaluamos el sistema en los cuatro subconjuntos de C-MAPSS (FD001–FD004) con $N_{\text{semillas}} = 10$ ejecuciones deterministas, intervalos de confianza bootstrap al 95 % y pruebas de Wilcoxon pareadas. El sistema propuesto logra un tiempo de adelanto medio de 33–56 ciclos entre el disparo de la compuerta y el punto de truncamiento de la trayectoria, una tasa de verdaderos positivos a nivel de sistema del 80–100 % y una tasa de falsas alarmas a nivel de sistema del 5–22 % bajo la configuración óptima ($\tau=P_{99}$). En la zona crítica ($\text{RUL} \leq 30$ ciclos) el error de RUL es de 5,4–10,1 ciclos; reportamos este error de zona crítica como una figura operacional absoluta en lugar de como una mejora sobre el RMSE de la última ventana de prueba, ya que ambos se calculan sobre distribuciones de RUL distintas y no son directamente comparables. En los dos conjuntos de datos multi-régimen (FD002, FD004) nuestro mejor regresor por conjunto de datos iguala o mejora el RMSE publicado sobre la última ventana de prueba, mientras que en los conjuntos de datos de régimen único permanece entre 2,5–4 ciclos por encima de los mejores valores reportados. El artículo aporta: (i) una definición formal de métricas a nivel de sistema para sistemas PHM jerárquicos, (ii) una ablación sobre percentiles de umbral y requisitos de persistencia que cuantifica la relación entre tasa de disparo y tasa de falsas alarmas, y (iii) un pipeline reproducible publicado con semillas deterministas, registros de ejecución y hashes SHA-256.

Keywords: Vida útil residual, Mantenimiento predictivo, Autoencoder variacional, Compuerta jerárquica, Cuantificación de incertidumbre, C-MAPSS

1. Introducción

Las tecnologías de pronóstico son cada vez más centrales en la aviación moderna. En los motores de aeronaves esto constituye un requisito fundamental, ya que su ciclo de vida está sometido a regímenes de operación que causan una degradación progresiva y, en última instancia, el fallo. Por esta razón, los motores modernos están equipados con sensores que registran señales de temperatura, presión y velocidad rotacional, proporcionando un flujo multivariante a partir del cual puede inferirse el proceso de deterioro. Las estrategias de mantenimiento preventivo o correctivo tradicionales (Azadeh et al., 2015) son cada vez menos capaces de satisfacer la creciente demanda industrial de eficiencia y fiabilidad. La presión económica sobre la aviación comercial es aguda: el informe de perspectivas de la IATA para 2026 (International Air Transport Association, 2026) señala los retrasos en las entregas y los costes de descarbonización como

vientos en contra para la rentabilidad de las aerolíneas, y el plan de negocio de la OACI para 2026–2028 (International Civil Aviation Organization, 2026) enumera explícitamente la supervisión de seguridad basada en datos entre sus prioridades estratégicas. El lado regulatorio también ha avanzado: la Agencia Europea de Seguridad Aérea ha publicado la segunda iteración de su hoja de ruta para la IA (European Union Aviation Safety Agency, 2025), que condiciona la adopción de modelos de aprendizaje automático en contextos de aviación críticos para la seguridad a la trazabilidad, la notificación de incertidumbre y la reproducibilidad –requisitos que cualquier sistema de RUL con aspiraciones de despliegue debe satisfacer.

Las técnicas de gestión de salud y pronósticos (PHM, por sus siglas en inglés) (Tian, 2012; Xu and Saleh, 2021) han madurado por tanto hasta convertirse en una herramienta estándar para industrias como la aeronáutica, en la que la estimación de la Vida Útil Residual (RUL) (Si et al., 2011) se ha convertido en un elemento clave para planificar el mantenimiento, prolongar el tiempo de vuelo y evitar eventos no programados.

*Autor para correspondencia.

Email address: rafapecino@gmail.com (Rafael Pecino Bonilla)

1.1. Revisión de la literatura

En la última década, dos corrientes principales han dado forma a la estimación de RUL basada en datos: los enfoques basados en modelos y los puramente basados en datos. Los métodos basados en modelos se apoyan en conocimiento físico que raramente está disponible en la práctica industrial, mientras que los métodos basados en datos aprenden los patrones de degradación directamente a partir de registros de sensores. Dentro de este último grupo, las líneas base de aprendizaje automático como los perceptrones multicapa (Tian, 2012), la Regresión de Vectores Soporte (Khelif et al., 2017) y el Gradient Boosting (Babu et al., 2016) proporcionaron los primeros resultados sistemáticos en el benchmark NASA C-MAPSS (Saxena et al., 2008). Los métodos de aprendizaje profundo dominaron posteriormente el clasificador: las Redes Neuronales Convolucionales 1D (Li et al., 2018), las redes de Memoria a Largo-Corto Plazo (Zheng et al., 2017; Asif et al., 2022), LSTM bidireccional con atención (Chen et al., 2020; Mo et al., 2022), Transformers con codificación posicional (Zhu et al., 2021), CNN-Transformer híbrido (Song et al., 2023) y diseños de doble atención (Liu et al., 2023; Wang et al., 2024) redujeron el RMSE por debajo de 12 ciclos en FD001. Un trabajo más reciente ha comenzado también a aplicar grandes modelos de series temporales preentrenados con adaptación de bajo rango a C-MAPSS (Chakravarty, 2025), señalando un cambio hacia el pronóstico basado en modelos de fundamento.

Una línea de trabajo paralela utiliza autoencoders para el diagnóstico no supervisado. Costa and Sánchez (2022) propuso un Codificador Variacional Recurrente (RVE) para C-MAPSS que construye un espacio latente bidimensional interpretable y supera a la mayoría de las líneas base en RMSE. La inferencia variacional también se explota en Ellefsen et al. (2019) y Xiang et al. (2021) para la predicción semisupervisada de RUL, mientras que Martínez-García et al. (2019) utiliza un autoencoder para la monitorización visual de la salud. La cuantificación de incertidumbre mediante MC Dropout se ha utilizado para exponer la incertidumbre epistémica en las estimaciones de RUL (Xu and Saleh, 2021).

1.2. Limitaciones de los enfoques actuales

A pesar de las notables mejoras en RMSE, persisten tres limitaciones. En primer lugar, la detección de anomalías y la estimación de RUL se reportan típicamente como métricas independientes. La mayoría de los trabajos reportan ROC-AUC para indicadores de anomalía o RMSE para la predicción de RUL, pero no ambos como parte de un único pipeline de decisión que un operador de mantenimiento pudiera desplegar. En segundo lugar, el RMSE canónico sobre la última ventana de prueba (Li et al., 2018) promedia sobre una región plana grande de muestras “sanas” de RUL alto (limitado a 125 ciclos) y una región crítica mucho más pequeña ($RUL \leq 30$): un RMSE pequeño en esta métrica agregada no implica un error pequeño en la zona operativamente significativa. En tercer lugar, los pocos sistemas que combinan un detector de anomalías con un regresor (p. ej., disparar el regresor solo tras una alerta) reportan métricas “condicionales” evaluadas en un subconjunto no estacionario incomparable con la métrica canónica de la última ventana de prueba, lo que conduce a una filtración métrica no intencionada.

1.3. Contribuciones

Este trabajo propone y evalúa un sistema jerárquico de anomalías a RUL que aborda explícitamente estos tres problemas:

1. Una capa de compuerta jerárquica *independiente del detector* que convierte cualquier puntuador de anomalías a nivel de ventana en un disparador cuantificado con un umbral calibrado y una regla de persistencia; la instanciamos con un Conv1D-VAE que preserva la estructura temporal y demostramos que es competitivo con los detectores clásicos no supervisados al tiempo que proporciona adicionalmente una representación latente de degradación (Sección 3.2, Tabla 4).
2. Una definición formal de métricas a nivel de sistema: tasa de verdaderos positivos a nivel de sistema (TPR_{sys}), tasa de falsas alarmas a nivel de sistema (FAR_{sys}), tiempo de adelanto (ciclos entre el disparo y el truncamiento de la trayectoria) y $RMSE@crítico$ (RMSE evaluado únicamente en ventanas con $RUL \leq 30$) que es comparable entre modelos y conjuntos de datos (Sección 2.4).
3. Un pipeline completamente reproducible con algoritmos de entrenamiento deterministas (la inferencia MC Dropout sigue siendo estocástica por diseño), $N_{semillas}=10$ ejecuciones, ICs bootstrap al 95 %, pruebas de Wilcoxon pareadas y un JSON de registro de ejecución con hashes SHA-256 que cubren pesos de modelo, particiones de datos, configuración y métricas agregadas (Sección 4.3).
4. Una ablación sobre percentiles de umbral ($\tau \in \{P_{85}, \dots, P_{99}\}$), valores de persistencia ($p \in \{1, 2, 3, 5\}$) y arquitectura VAE (FC vs. Conv1D) que cuantifica la relación operacional y revela $\tau=P_{99}$ como óptimo en los cuatro conjuntos de datos (Sección 5.4).

El resto del artículo está organizado como sigue. La Sección 2 introduce el entorno del problema y el formalismo de métricas. La Sección 3 detalla los componentes del modelo y la lógica de compuerta jerárquica. La Sección 4 describe el diseño experimental. La Sección 5 reporta la evaluación empírica, las ablaciones y la comparación con el estado del arte. La Sección 6 extrae conclusiones y esboza el trabajo futuro.

2. Planteamiento del problema

2.1. Estimación de RUL

La Vida Útil Residual (RUL) es el número de ciclos de operación entre la observación actual y el momento en que el sistema alcanza un estado definido como fallo. Siguiendo la configuración canónica del benchmark C-MAPSS (Saxena et al., 2008), las trayectorias de entrenamiento son de funcionamiento hasta el fallo (el evento de fallo se observa en el último ciclo), mientras que las trayectorias de prueba están truncadas en un desplazamiento conocido, y el RUL de verdad terreno en ese desplazamiento se proporciona en un fichero separado. El objetivo es aprender una función $f: \mathbb{R}^{w \times d} \rightarrow \mathbb{R}_{\geq 0}$ que mapee una ventana deslizante de w observaciones multicanal a un RUL real no negativo.

Cuadro 1: Resumen de los subconjuntos de datos C-MAPSS (Saxena et al., 2008).

	FD001	FD002	FD003	FD004
Trayectorias de entrenamiento	100	260	100	240
Trayectorias de prueba	100	259	100	248
Regímenes de operación	1	6	1	6
Modos de fallo	1	1	2	2

2.2. Objetivo de RUL lineal a tramos

Siguiendo la práctica estándar (Heimes, 2008; Li et al., 2018), el RUL objetivo está limitado a $RUL_{\max} = 125$ ciclos, dando lugar a una función por tramos con una etapa sana constante y una etapa de descenso lineal. Esta convención refleja la suposición física de que el motor opera en régimen nominal hasta un punto de inflexión a partir del cual la degradación se vuelve aparente (Costa and Sánchez, 2022). Dado que el límite colapsa todos los objetivos de vida temprana a un valor constante, la etapa sana utilizada para entrenar el VAE (Sección 3.2) coincide con esta región plana; la sensibilidad del sistema a esta suposición se discute en la Sección 6.1.

2.3. Conjuntos de datos

El benchmark C-MAPSS contiene cuatro subconjuntos de datos que difieren en el número de regímenes de operación y modos de fallo (Tabla 1). FD001 y FD003 comparten un único régimen de operación; FD002 y FD004 exponen seis. FD003 y FD004 introducen un segundo modo de fallo. Los cuatro subconjuntos están ordenados por dificultad creciente: $FD001 < FD003 < FD002 < FD004$.

2.4. Métricas

Métricas de regresión de RUL a nivel de ventana.. Las métricas canónicas sobre la última ventana de prueba son la Raíz del Error Cuadrático Medio (RMSE) y la puntuación asimétrica NASA S , que penaliza más las predicciones tardías que las tempranas (Saxena et al., 2008):

$$RMSE = \sqrt{\frac{1}{N} \sum_{i=1}^N (\hat{r}_i - r_i)^2}, \quad (1)$$

$$S = \sum_{i=1}^N s_i, \quad s_i = \begin{cases} e^{-d_i/13} - 1, & d_i < 0, \\ e^{d_i/10} - 1, & d_i \geq 0, \end{cases} \quad (2)$$

con $d_i = \hat{r}_i - r_i$ y N el número de ventanas evaluadas.

Métrica de zona crítica.. Como se discute en la Sección 1.2, el RMSE de la última ventana de prueba promedia una gran región sana con una pequeña región crítica. Por tanto, introducimos el $RMSE@crítico$, calculado sobre todas las ventanas deslizantes de la trayectoria de prueba cuyo RUL de verdad terreno sea igual o inferior a un umbral crítico $\rho_{crit} = 30$ ciclos:

$$RMSE@crítico = \sqrt{\frac{1}{|C|} \sum_{i \in C} (\hat{r}_i - r_i)^2}, \quad (3)$$

con $C = \{i : r_i \leq \rho_{crit}\}$. Esta métrica es comparable entre modelos porque todos ellos se evalúan en el mismo conjunto de ventanas.

Métricas a nivel de sistema.. Para el sistema jerárquico, sea el tiempo de disparo t_u^* el ciclo del último paso temporal de la primera ventana del motor u para la que esa ventana y las $p - 1$ ventanas inmediatamente precedentes superan todas el umbral τ (regla de persistencia); si no existe tal secuencia, el motor no es disparado. Particionamos los motores de prueba en el conjunto crítico $C = \{u : \min_t r_t^{(u)} \leq \rho_{crit}\}$ ($N_{crit} = |C|$) y el conjunto operativamente sano $\mathcal{H} = \{u : \min_t r_t^{(u)} > \rho_{crit}\}$ ($N_{sano} = |\mathcal{H}|$), y sea $\mathcal{T}$ el conjunto de motores disparados. Definimos:

$$\Delta_u = T_u - t_u^*, \quad (T_u: \text{ciclo de truncamiento de } u), \quad (4)$$

$$TPR_{sys} = \frac{|C \cap \mathcal{T}|}{N_{crit}}, \quad FAR_{sys} = \frac{|\mathcal{H} \cap \mathcal{T}|}{N_{sano}}. \quad (5)$$

Una advertencia persistente en un motor que sí alcanza la zona crítica se puntúa como verdadero positivo independientemente de cuándo se produce. Se aplican dos advertencias. Primera, el tiempo de adelanto se mide hasta el ciclo de *truncamiento* de C-MAPSS T_u , no hasta un fallo físicamente observado, ya que las trayectorias de prueba terminan en un desplazamiento conocido. Segunda, dado que las trayectorias de prueba están censuradas por la derecha, $\mathcal{H}$ contiene motores cuya trayectoria *censurada* no alcanza la zona crítica en lugar de motores que son sanos durante toda su vida; FAR_{sys} por tanto acota por arriba la tasa de falsas alarmas operacional. Los valores de N_{crit} y N_{sano} por conjunto de datos se reportan junto con los resultados de la compuerta.

Calibración de incertidumbre.. Para las estimaciones de MC Dropout reportamos PICP@95 % (cobertura empírica del intervalo predictivo $\hat{\mu} \pm 1.96\hat{\sigma}$), MPIW (anchura media del intervalo de predicción), Log-Verosimilitud Negativa bajo suposición gaussiana y Error de Calibración Esperado (Guo et al., 2017) calculado en $n_{bins} = 10$ niveles de confianza.

3. Método

3.1. Visión general del pipeline

El sistema propuesto está compuesto por tres etapas, representadas en la Fig. 1:

1. **Preprocesamiento:** agrupamiento de régimen con KMeans sobre las señales de condición de operación (ajustado únicamente en la partición de entrenamiento), escalado mín-máx por régimen y etiquetado de RUL lineal por tramos con límite 125 (Sección 4.1).
2. **Detección de anomalías:** un Conv1D-VAE entrenado exclusivamente en el primer 30 % de cada trayectoria de entrenamiento (la «etapa sana») con un subconjunto retenido de motores sanos reservado para la calibración del umbral.
3. **Regresión de RUL con compuerta jerárquica:** cuando el VAE alerta sobre un motor, un regresor Transformer (o alternativamente CNN+LSTM) predice el RUL, y la predicción se enriquece con una banda MC Dropout de $\pm 2\hat{\sigma}$. Antes del disparo, el sistema no emite ninguna estimación de RUL y declara el motor sano; un valor de RUL con su

banda de incertidumbre se produce únicamente a partir de t_u^* en adelante.

Todas las métricas a nivel de sistema (tiempo de adelanto, TPR_{sys} , FAR_{sys} y RMSE@crítico) se calculan sobre la trayectoria de prueba completa con paso 1 de modo que se refieran al mismo conjunto de ventanas; el tiempo de disparo t_u^* que define el tiempo de adelanto es el primer ciclo que satisface la regla de persistencia de la Sección 3.5.

3.2. Detección de anomalías: autoencoder variacional

Un VAE completamente conectado estándar aplana cada ventana $w \times d$ en un vector largo antes de mapearla al espacio latente, lo que destruye el orden temporal de las observaciones. Para preservar la estructura temporal, proponemos un codificador Conv1D-VAE con tres bloques convolucionales de 32, 64 y 128 canales (tamaño de núcleo 5, 5 y 3, con dos capas de stride 2), seguidos de una proyección completamente conectada a un espacio latente gaussiano 16-dimensional. El decodificador refleja el codificador con convoluciones transpuestas. Ambas arquitecturas se entrenan con la función de pérdida ELBO estándar

$$\mathcal{L}_{\text{VAE}} = \text{MSE}(\hat{x}, x) + \beta D_{\text{KL}}(q_{\phi}(z | x) \| \mathcal{N}(0, I)), \quad (6)$$

con $\beta = 0,1$, un valor que favorece deliberadamente la fidelidad de reconstrucción –y por tanto una señal de error de reconstrucción más nítida para la compuerta– sobre el desacoplamiento latente. El VAE se entrena únicamente en el primer 30 % de cada trayectoria de entrenamiento (considerado sano), y el 20 % de estos motores sanos se retiene y no es visto nunca por el codificador; el umbral τ es el percentil q -ésimo de los errores de reconstrucción por ventana agrupados sobre todas las ventanas de este conjunto retenido, eliminando la filtración de calibración que surgiría si τ se fijase en los mismos datos utilizados para ajustar el codificador. Un único VAE se entrena a través de todos los regímenes de operación –en contraste con el escalado por régimen de la Sección 4.1– y el impacto de este diseño agnóstico al régimen sobre la tasa de falsas alarmas multi-régimen se analiza en la Sección 6.1.

3.3. Líneas base de regresión de RUL

Random Forest. Cada ventana se resume mediante siete estadísticos por sensor (media, desviación típica, mínimo, máximo, pendiente, asimetría, curtosis), produciendo un vector de características $7d$ -dimensional que alimenta un Random Forest con 200 árboles, profundidad 15 y mínimo de hoja 5. El RF actúa como la línea base interpretable: cualquier modelo profundo que no supere consistentemente al RF en RMSE@crítico no justifica su complejidad adicional.

CNN 1D + LSTM. Dos capas convolucionales 1D (32 y 64 canales, núcleo 5, dropout 0,2) extraen características locales, seguidas de un LSTM de dos capas con tamaño oculto 64. El último estado oculto alimenta una pequeña cabeza completamente conectada con dropout. Las capas de dropout se reutilizan en la inferencia para MC Dropout (Sección 3.4).

Transformer. Una proyección lineal ($d \rightarrow 64$) y una codificación posicional sinusoidal alimentan dos capas TransformerEncoder (4 cabezas, dimensión feed-forward 128, activación GELU, dropout 0,2). El promediado de la dimensión temporal produce la entrada de la cabeza de regresión.

Todos los regresores profundos se entrenan con AdamW, pérdida MSE, recorte de gradiente en norma 1, planificador ReduceLROnPlateau y parada temprana sobre MSE de validación.

3.4. Incertidumbre epistémica: MC Dropout

Siguiendo Gal and Ghahramani (2016), activamos el dropout en el tiempo de inferencia y muestreamos $T = 50$ pasadas estocásticas hacia adelante por ventana, obteniendo la media predictiva $\hat{\mu}$ y la desviación típica $\hat{\sigma}$. El intervalo $\hat{\mu} \pm 1,96\hat{\sigma}$ es la banda predictiva al 95 % reportada en las Tablas 5 y 7. En una única GPU la inferencia MC Dropout con $T=50$ cuesta 0,3–1,7 ms por ventana, bien dentro de los presupuestos de monitorización en tiempo real.

3.5. Compuerta jerárquica

La lógica de compuerta es una capa de decisión explícita sobre los componentes descritos anteriormente. Para cada motor u en el conjunto de prueba, consideramos la trayectoria completa de ventanas deslizantes (paso 1). El vector de error de reconstrucción $\{e_t^{(u)}\}_{t=1}^{T_u}$ se umbraliza contra τ para producir una corriente de indicadores. Se declara un disparo en el primer ciclo t_u^* tal que el indicador está activo durante al menos p ventanas consecutivas. El parámetro de persistencia p filtra indicadores espurios y negocia la tasa de disparo contra el tiempo de adelanto. Dado que las ventanas consecutivas de paso 1 se solapan en $w-1$ ciclos, p actúa como un filtro de eliminación de ruido temporal en lugar de una secuencia de confirmaciones estadísticamente independientes.

Separamos deliberadamente dos métricas que a veces se confunden en la literatura:

- $\text{RMSE}_{\text{completo}}$: RMSE del regresor en cada ventana de la trayectoria de prueba.
- $\text{RMSE}_{\text{cond}}$: RMSE del mismo regresor evaluado únicamente en las ventanas posteriores al disparo.

Estos dos valores no son comparables: se calculan en subconjuntos distintos y por tanto en distribuciones de RUL diferentes. Reportar $\text{RMSE}_{\text{cond}} < \text{RMSE}_{\text{completo}}$ como evidencia de un beneficio carece de fundamento. En su lugar utilizamos el RMSE@crítico comparable de la Ec. (3) como métrica de interés en la zona operacional, y reportamos $\text{RMSE}_{\text{completo}}/\text{RMSE}_{\text{cond}}$ solo por completitud con una nota explícita (Tabla 10).

4. Diseño experimental

4.1. Preprocesamiento

Para FD001 y FD003 (régimen único), se ajusta un escalador mín-máx global en la partición de entrenamiento. Para FD002 y FD004 (seis regímenes), se ajusta KMeans con $k=6$ en las




Figura 1: Pipeline del sistema: un Conv1D-VAE entrenado únicamente con datos sanos actúa como compuerta cuantificada; un Transformer con MC Dropout produce la estimación de RUL cuando el VAE dispara. El tiempo de adelanto, TPR_{sys} y FAR_{sys} se reportan conjuntamente con el RMSE de la última ventana de prueba y de la zona crítica.

señales de condición de operación de la partición de entrenamiento, y se ajusta un escalador mín-máx separado por clúster. Tanto las etiquetas KMeans como las estadísticas por régimen se obtienen exclusivamente en la partición de entrenamiento, y solo se aplican a los datos de validación/prueba (sin filtración). Los sensores constantes con varianza inferior a 10^{-6} se eliminan (6 en FD001, 5 en FD003, ninguno en FD002/FD004); las características restantes se seleccionan por la correlación de Spearman absoluta entre sensor y RUL lineal en el conjunto de entrenamiento, reteniendo 15 sensores en FD001 y FD002 y 11 en FD003 y FD004. Utilizamos un umbral de correlación de 0,10 para los conjuntos de datos de régimen único (FD001/FD003) y un 0,05 más bajo para los conjuntos de datos de seis regímenes (FD002/FD004): en el caso multi-régimen, la correlación agrupada sensor-RUL se ve atenuada, porque un sensor que es informativo *dentro* de cada régimen de operación puede exhibir un coeficiente bajo una vez que los seis regímenes se mezclan, por lo que se requiere un umbral más bajo para retener esos sensores. El preprocesamiento se aplica por ciclo en el orden asignación de régimen → escalado mín-máx por régimen → extracción de ventanas deslizantes, de modo que cada paso temporal se escala por las estadísticas de su propio régimen antes de que se forme ninguna ventana.

4.2. Ventanas deslizantes y particiones

Se utiliza un tamaño de ventana de $w=30$ ciclos (consistente con (Li et al., 2018)). Entrenamiento: cada ventana válida con paso 1 de cada motor. Validación: 10 % de los motores (retenidos por engine_id, no por ventana). Última ventana de prueba: la última ventana de w de cada motor de prueba, con relleno por repetición del primer fotograma para trayectorias más cortas que w . La trayectoria de prueba completa (cada ventana con paso 1) también se calcula y se utiliza para el análisis de compuerta y la métrica RMSE@crítico. Los motores cuya trayectoria (rellenada) produce menos de p ventanas con paso 1 solo pueden dispararse en $p=1$; esto afecta a una fracción despreciable del conjunto de prueba, para la que la regla de persistencia se reduce a un indicador de ventana única.

4.3. Reproducibilidad y protocolo estadístico

Todos los experimentos se ejecutan con SEMILLA=42. Las semillas de Python, NumPy, PyTorch y CUDA están

Cuadro 2: Hiperparámetros de los modelos. Comunes a todos los modelos profundos: ventana $w=30$, límite RUL 125, tamaño de lote 256, recorte de gradiente en norma 1,0, ReduceLROnPlateau (factor 0,5, paciencia 4), MC Dropout $T=50$.

Modelo	Hiperparámetros
Conv1D-VAE	canales cod. 32/64/128 (núcleos 5/5/3, dos stride-2), latente 16, $\beta=0,1$, Adam lr 10^{-3} , 80 épocas
CNN+LSTM	conv 32/64 (núcleo 5, dropout 0,2), LSTM oculto 64 ($\times 2$ capas), cabeza 64 $\rightarrow$ 32 $\rightarrow$ 1, AdamW lr 10^{-3} , decay 10^{-4} , ≤ 60 épocas, parada temprana (paciencia 8)
Transformer	$d_{\text{modelo}}=64$, 4 cabezas, FF 128, 2 capas, GELU, dropout 0,2, AdamW lr 5×10^{-4} , wd 10^{-4} , ≤ 60 épocas
Random Forest	200 árboles, profundidad máx 15, mín muestras hoja 5, 7d características de ventana (semilla única)

fijadas. `torch.use_deterministic_algorithms(True)` y `torch.nn.deterministic=True` están activados, y el DataLoader usa una función de semilla por trabajador y un `torch.Generator` sembrado. Cada regresor profundo se entrena $N_{\text{semillas}}=10$ veces con semillas {42, 43, ..., 51}, obteniendo una muestra de 10 valores de RMSE / NASA / RMSE@crítico por conjunto de datos. Todas las métricas agregadas se reportan como media e intervalo de confianza bootstrap por percentil al 95 % (2000 remuestreos). Las comparaciones pareadas entre CNN+LSTM y Transformer usan la prueba de rangos con signo de Wilcoxon bilateral pareada. La configuración completa, las semillas, la versión de cada dependencia y las métricas agregadas se guardan en un `run_log.json` con un hash SHA-256, permitiendo la reproducción exacta. Los hiperparámetros de cada modelo se resumen en la Tabla 2; el entrenamiento utilizó una única GPU NVIDIA (Google Colab, PyTorch 2.11 / CUDA 12.8).

5. Resultados

5.1. Rendimiento de la detección de anomalías

La Tabla 3 reporta ROC-AUC y PR-AUC para las variantes FC y Conv1D del VAE sobre la trayectoria de prueba completa, junto con el porcentaje de ventanas por encima del umbral

Cuadro 3: Detección de anomalías a nivel de ventana. El mejor en negrita por conjunto de datos.

Conjunto	Arq.	ROC-AUC	PR-AUC	TPR@ τ	FAR@ τ
FD001	FC	0,921	0,444	71,4 %	5,8 %
	Conv1D	0,951	0,585	81,3 %	7,5 %
FD002	FC	0,971	0,697	97,0 %	18,2 %
	Conv1D	0,970	0,698	97,0 %	19,3 %
FD003	FC	0,966	0,606	82,1 %	5,7 %
	Conv1D	0,971	0,658	89,0 %	8,3 %
FD004	FC	0,940	0,395	84,4 %	11,5 %
	Conv1D	0,950	0,433	87,0 %	11,4 %

(TPR@ τ) y la tasa de falsas alarmas a nivel de ventana correspondiente (FAR@ τ). El Conv1D-VAE supera a la línea base FC en tres de los cuatro conjuntos de datos (ganancia en ROC-AUC de +0,030, +0,005 y +0,010 para FD001, FD003, FD004 respectivamente; empate en FD002), confirmando que preservar la estructura temporal beneficia la detección de anomalías.

Para contextualizar el Conv1D-VAE, la Tabla 4 lo compara contra tres detectores clásicos no supervisados ajustados en las mismas ventanas sanas –distancia de Mahalanobis (covarianza Ledoit–Wolf), una SVM de una clase y un Isolation Forest– en la tarea idéntica (positivo: ventanas con $RUL \leq 30$ sobre la trayectoria de prueba completa). El Conv1D-VAE es *competitivo pero no sistemáticamente superior*: la SVM de una clase y el Isolation Forest lo igualan o superan ligeramente en ROC-AUC en FD001 y FD003, el VAE y la SVM de una clase están empatados en FD002, y la distancia de Mahalanobis lo supera en FD004. No obstante, adoptamos el Conv1D-VAE como el detector por defecto por dos razones más allá de la precisión de detección bruta: produce una representación latente estructurada que expone la variedad de degradación (Sección 5.7) y se integra de forma natural con el pipeline de incertidumbre de MC Dropout. Crucialmente, la capa de compuerta jerárquica que constituye la contribución principal de este artículo es *independiente del detector*: cualquiera de estos puntuadores puede conectarse sin cambiar las definiciones de métricas a nivel de sistema, y los valores de ROC-AUC casi equivalentes indican que los resultados operacionales no son un artefacto del detector específico elegido.

5.2. Regresión de RUL

La Tabla 5 reporta el RMSE de la última ventana de prueba, la puntuación NASA y el RMSE@crítico para los tres regresores. El Random Forest de semilla única proporciona la línea base interpretable. CNN+LSTM y Transformer son los regresores profundos; sus resultados son la media e IC bootstrap al 95 % sobre 10 semillas.

El RMSE@crítico (5,4–10,1 ciclos) es numéricamente menor que el RMSE de la última ventana de prueba, pero los dos no son directamente comparables: se evalúan en conjuntos de ventanas distintos y por tanto en distribuciones de RUL diferentes, ya que la zona crítica excluye la gran región sana limitada. Por tanto, leemos el RMSE@crítico como un error absoluto en la zona relevante para el mantenimiento en lugar de como una mejora sobre la figura global. Dentro de esta zona, los regresores profundos

Cuadro 4: Rendimiento de detección frente a líneas base clásicas no supervisadas (positivo: $RUL \leq 30$ sobre la trayectoria de prueba completa). El mejor por conjunto de datos en negrita.

Conjunto	Detector	ROC-AUC	PR-AUC
FD001	Mahalanobis	0,913	0,403
	SVM de una clase	0,970	0,637
	Isolation Forest	0,970	0,608
	Conv1D-VAE (nuestro)	0,945	0,536
FD002	Mahalanobis	0,958	0,548
	SVM de una clase	0,972	0,710
	Isolation Forest	0,965	0,669
	Conv1D-VAE (nuestro)	0,972	0,700
FD003	Mahalanobis	0,912	0,485
	SVM de una clase	0,980	0,643
	Isolation Forest	0,980	0,603
	Conv1D-VAE (nuestro)	0,971	0,661
FD004	Mahalanobis	0,968	0,496
	SVM de una clase	0,954	0,409
	Isolation Forest	0,963	0,417
	Conv1D-VAE (nuestro)	0,945	0,423

son consistentemente mejores que la línea base del Random Forest (p. ej. 5,60 frente a 6,68 ciclos en FD001), lo que justifica su complejidad adicional. Las pruebas de Wilcoxon de rangos con signo pareadas sobre los valores de RMSE y NASA por semilla (Tabla 6) confirman que el Transformer no domina uniformemente al CNN+LSTM. Tras la corrección de Holm–Bonferroni para las cuatro comparaciones simultáneas, el CNN+LSTM sigue siendo significativamente mejor en FD001 (p ajustado = 0,008, $d_z = +1,19$) y el Transformer en FD003 (p ajustado = 0,008, $d_z = -2,15$); la ventaja nominal del CNN+LSTM en FD004 *no* sobrevive a la corrección (p ajustado = 0,074), y los dos modelos son estadísticamente indistinguibles en FD002. Esta complementariedad apoya la selección de modelo por conjunto de datos o el ensamblado como dirección futura.

5.3. Calibración de la incertidumbre

La Tabla 7 reporta las métricas de calibración brutas para el Transformer con $T=50$ pasadas MC Dropout. El PICP está cerca del objetivo nominal del 95 % en los conjuntos de datos de régimen único (89,0 % en FD001 y 86,0 % en FD003) con ECE por debajo de 0,06; en los conjuntos de datos multi-régimen el modelo es sobre-confiado –los intervalos predictivos son demasiado estrechos y cubren por debajo el RUL verdadero (PICP 74,5 % en FD002 y 74,2 % en FD004, muy por debajo del nivel nominal del 95 %)– con ECE de 0,11–0,12. Por tanto, aplicamos una recalibración post-hoc que reescala la desviación típica predictiva $\hat{\sigma}$ por un único factor escalar s ajustado en el conjunto de validación de modo que el PICP de validación alcance el nivel nominal del 95 %. Esto restaura la cobertura de prueba al 90–95 % en los conjuntos de datos multi-régimen (FD002: 74,5 % $\rightarrow$ 95,4 % con $s=1,90$; FD004: 74,2 % $\rightarrow$ 89,9 % con $s=1,55$) y reduce el ECE por debajo de 0,07 (Tabla 8), al coste esperado de intervalos más anchos. Las bandas $\pm 2\hat{\sigma}$ mostradas en la Fig. 2 usan el $\hat{\sigma}$ recalibrado.

Cuadro 5: Métricas de regresión de RUL (media e IC bootstrap al 95 % sobre $N_{\text{semillas}}=10$). El mejor modelo profundo en negrita por conjunto de datos.

Conjunto	Modelo	RMSE	NASA	RMSE@crítico
FD001	Random Forest	13,40	293	6,68
	CNN+LSTM	13,58 [13,36, 13,81]	317 [306, 328]	5,60 [5,01, 6,41]
	Transformer	14,28 [14,09, 14,47]	420 [396, 443]	5,60 [5,17, 6,03]
FD002	Random Forest	14,85	878	8,14
	CNN+LSTM	14,08 [13,94, 14,21]	996 [944, 1051]	8,36 [7,69, 9,08]
	Transformer	14,01 [13,72, 14,39]	1079 [989, 1182]	7,56 [7,21, 7,92]
FD003	Random Forest	14,00	424	6,80
	CNN+LSTM	15,30 [15,06, 15,54]	642 [569, 727]	8,35 [7,17, 9,64]
	Transformer	14,05 [13,77, 14,36]	489 [419, 558]	5,41 [5,06, 5,81]
FD004	Random Forest	17,54	1975	14,30
	CNN+LSTM	16,44 [16,26, 16,64]	1317 [1256, 1372]	10,09 [9,32, 10,91]
	Transformer	17,14 [16,78, 17,51]	1860 [1644, 2125]	10,63 [9,52, 11,66]

Cuadro 6: Prueba de Wilcoxon de rangos con signo pareada (bilateral) sobre RMSE por semilla, $N_{\text{semillas}}=10$. ΔRMSE y d_z se definen ambos como Transformer menos CNN+LSTM, por lo que un valor *positivo* favorece al CNN+LSTM (menor RMSE). p_{Holm} es el p -valor ajustado por Holm–Bonferroni sobre los cuatro conjuntos de datos; la significación usa p_{Holm} .

Conjunto	RMSE C+L	RMSE Trf	ΔRMSE	p	p_{Holm}	d_z
FD001	13,58	14,28	+0,70	0,0020	0,0078 **	+1,19
FD002	14,08	14,01	−0,07	0,3750	0,3750 ns	−0,10
FD003	15,30	14,05	−1,25	0,0020	0,0078 **	−2,15
FD004	16,44	17,14	+0,71	0,0371	0,0742 ns	+0,93

Cuadro 7: Calibración MC Dropout del Transformer ($T=50$), bruta (antes de la recalibración).

Conjunto	PICP@95 %	MPIW	NLL	ECE
FD001	89,0 %	41,5	4,09	0,057
FD002	74,5 %	35,0	4,40	0,108
FD003	86,0 %	43,1	4,02	0,055
FD004	74,2 %	44,0	5,13	0,123

Cuadro 8: Recalibración post-hoc del $\hat{\sigma}$ predictivo del Transformer por un escalar s ajustado en validación (objetivo PICP = 95 %): PICP y ECE de prueba antes y después.

Conjunto	s	PICP _{bruto}	PICP _{recal}	ECE _{bruto}	ECE _{recal}
FD001	1,40	89,0 %	95,0 %	0,057	0,048
FD002	1,90	74,5 %	95,4 %	0,108	0,073
FD003	1,35	86,0 %	92,0 %	0,055	0,044
FD004	1,55	74,2 %	89,9 %	0,123	0,035

5.4. Compuerta jerárquica: ablación y configuración seleccionada

El sistema fue evaluado bajo el producto cartesiano completo de $\tau \in \{P_{85}, P_{90}, P_{95}, P_{97}, P_{99}\}$, $p \in \{1, 2, 3, 5\}$ y arquitectura VAE $\in \{\text{FC}, \text{Conv1D}\}$, resultando en 40 configuraciones por conjunto de datos. La configuración que maximiza $\text{TPR}_{\text{sys}} - \text{FAR}_{\text{sys}}$ se reporta en la Tabla 9. El percentil 99 del error de reconstrucción sano retenido es consistentemente el umbral óptimo en los cuatro subconjuntos, mientras que el parámetro de persistencia varía de 1 a 5 según el nivel de ruido de cada conjunto de datos. Obsérvese que el criterio $\text{TPR}_{\text{sys}} - \text{FAR}_{\text{sys}}$ pondera por igual las detecciones perdidas y las falsas alarmas; un despliegue

Cuadro 9: Mejor configuración de compuerta por conjunto de datos (criterio: máx $\text{TPR}_{\text{sys}} - \text{FAR}_{\text{sys}}$).

Conjunto	VAE	τ	p	TPR_{sys}	FAR_{sys}	Adelanto
FD001	Conv1D	P_{99}	3	80,0 %	5,3 %	32,8
FD002	FC	P_{99}	5	98,4 %	17,7 %	39,3
FD003	Conv1D	P_{99}	1	100,0 %	22,5 %	51,8
FD004	Conv1D	P_{99}	2	94,3 %	21,5 %	55,8

Cuadro 10: Métricas a nivel de sistema bajo la configuración de compuerta seleccionada; $\text{RMSE}_{\text{completo}}$ y $\text{RMSE}_{\text{cond}}$ se reportan solo por completitud (subconjuntos incomparables).

Conjunto	Adelanto (medio)	TPR_{sys}	$\text{RMSE}_{\text{cond}}^*$	$\text{RMSE}_{\text{comp}}^*$
FD001	32,8	80,0 %	12,67	14,28
FD002	39,3	98,4 %	15,50	14,01
FD003	51,8	100,0 %	11,32	14,05
FD004	55,8	94,3 %	18,84	17,14

* $\text{RMSE}_{\text{cond}}$ y $\text{RMSE}_{\text{comp}}$ se calculan en ventanas distintas y ninguno se restringe a la zona crítica; no son directamente comparables. Para el error en zona crítica véanse la Tabla 11 y la Sección 3.5.

en aviación impondría en su lugar un coste asimétrico o una restricción dura (p. ej. $\text{FAR}_{\text{sys}} < 5\%$), bajo la cual los puntos de operación multi-régimen reportados aquí requerirían la compuerta condicional al régimen discutida en la Sección 6.1. El Conv1D-VAE gana en tres de los cuatro casos, confirmando la ganancia cualitativa reportada en la Sección 5.1.

El sistema proporciona un tiempo de adelanto medio de 33 a 56 ciclos entre el disparo y el punto de truncamiento de la trayectoria, con un TPR en zona crítica del 80–100 %. La FAR a nivel de sistema es del 5,3 % en FD001 (régimen único) pero sube al 17–23 % en los conjuntos de datos multi-régimen, una limitación conocida de los VAEs agnósticos al régimen que discutimos en la Sección 6.1.

Error en zona crítica condicionado al sistema.. Para medir el regresor donde el *sistema* opera realmente, recalculamos el RMSE en zona crítica sobre las ventanas que son simultáneamente críticas ($\text{RUL} \leq 30$) y posteriores al disparo de la compuerta de la configuración seleccionada. Una ventana crítica con último

Cuadro 11: RMSE en zona crítica del Transformer evaluado sobre todas las ventanas críticas frente a solo las ventanas críticas posteriores al disparo del sistema (mejor configuración por conjunto de datos). La cobertura es la fracción de ventanas críticas capturadas tras el disparo. Ambas columnas usan el modelo desplegado único sobre la trayectoria de prueba completa; la pequeña diferencia con el RMSE@crítico de la Tabla 5 refleja que este último es la media sobre las diez semillas.

Conjunto	Cobertura	RMSE@crit (todo)	RMSE@crit (post-disparo)
FD001	66,9 %	4,87	4,16
FD002	94,4 %	7,50	6,92
FD003	82,8 %	5,18	4,20
FD004	82,9 %	11,55	7,93

Cuadro 12: Sensibilidad de las métricas a nivel de sistema a la fracción sana utilizada para entrenar el VAE (Conv1D, $\tau=P_{99}$, persistencia 2).

Fracción sana	Conjunto	TPR _{sys}	FAR _{sys}
20 %	FD001	84,0 %	17,3 %
	FD004	94,3 %	22,1 %
30 %	FD001	80,0 %	8,0 %
	FD004	94,3 %	21,5 %
40 %	FD001	64,0 %	10,7 %
	FD004	88,7 %	16,4 %

ciclo s está *capturada* cuando el disparo la precede ($t_u^* \leq s$); la cobertura es la fracción de ventanas críticas capturadas, una cantidad a nivel de ventana distinta del TPR_{sys} a nivel de motor (un motor contribuye al TPR_{sys} en cuanto es disparado, incluso si algunas de sus ventanas críticas preceden al disparo). Restringir a la región posterior al disparo reduce el error en zona crítica en los cuatro conjuntos de datos (Tabla 11), de forma más marcada en FD004 (11,55 $\rightarrow$ 7,93 ciclos), mientras que la compuerta captura el 67–94 % de las ventanas críticas. La compuerta concentra por tanto el regresor en la región operativamente relevante en lugar de degradar su precisión allí.

Sensibilidad a la suposición de fracción sana.. El VAE se entrena en el primer 30 % de cada trayectoria, considerado sano. Para verificar que esta elección no es una fuente oculta de filtración o fragilidad, reentrenamos el Conv1D-VAE utilizando el 20 %, 30 % y 40 % de cada trayectoria y reevaluamos la compuerta ($\tau=P_{99}$, persistencia 2). Las métricas a nivel de sistema son estables en el rango 20–30 % (Tabla 12); solo al 40 % cae la tasa de verdaderos positivos en los conjuntos de datos de régimen único (p. ej. FD001 80 $\rightarrow$ 64 %), como se espera cuando ventanas degradadas comienzan a filtrarse en el conjunto de entrenamiento «sano». La convención del 30 % es por tanto un punto de operación seguro más que un valor ajustado.

5.5. Comparación con el estado del arte

La Tabla 13 compara el RMSE de la última ventana de prueba de nuestro mejor modelo con ocho enfoques publicados que siguen el mismo protocolo de última ventana de prueba en C-MAPSS. Nuestro mejor regresor *por conjunto de datos* —el Transformer en FD002 y el CNN+LSTM en FD004— está por encima del SOTA en los conjuntos de datos de régimen único (diferencia de +2,54 en FD001 y +2,67 en FD003) pero lo

mejora en los conjuntos de datos multi-régimen (diferencia de $-1,77$ en FD002 frente al Transformer de doble atención de Liu et al. (2023) y $-0,51$ en FD004 frente al CNN-LSTM-Atención híbrido de Wang et al. (2024)). Estas cifras reflejan la fortaleza de los regresores individuales, no de la capa de compuerta, que deja el RMSE de la última ventana de prueba sin cambios; se reportan solo para mostrar que los regresores orquestados por la compuerta siguen siendo competitivos en los conjuntos de datos más difíciles.

La contribución de este artículo no es, por tanto, reclamar un nuevo récord de RMSE en los conjuntos de datos fáciles, sino proporcionar una capa de compuerta operativamente significativa con tiempo de adelanto cuantificado y tasa de falsas alarmas, manteniéndose a la vez competitivo en RMSE bruto en los conjuntos de datos multi-régimen donde la dificultad es mayor.

5.6. Análisis de casos de fallo

Los 10 motores con mayor error por regresor fueron inspeccionados en cada conjunto de datos. Los motores que aparecen simultáneamente en el top-10 de los tres regresores forman un pequeño conjunto de unidades sistemáticamente difíciles (unidades 45, 67, 93 en FD001; 12, 221, 229 en FD002; 9, 19, 54, 85, 96 en FD003; 34, 39, 43, 107, 240 en FD004). El RUL de verdad terreno medio de estos motores se sitúa en 73–101 ciclos, es decir, lejos de la región de fallo. CNN+LSTM y Transformer sobreestiman el RUL en FD001–FD003 (es decir, son optimistas en ciclos hasta el fallo), mientras que los tres regresores subestiman en FD004. Ninguno de estos motores pertenece a la zona crítica operacional ($RUL \leq 30$); el sistema falla por tanto en la predicción a largo horizonte, no en el horizonte corto relevante para el mantenimiento, lo que es consistente con los resultados de RMSE@crítico de la Tabla 5. En los conjuntos de datos multi-régimen estos motores difíciles no se concentran en los regímenes de operación minoritarios: caen casi en su totalidad en el régimen dominante (8/8 en FD002 y 8/9 en FD004 pertenecen al régimen más poblado), confirmando que la dificultad es el RUL a largo horizonte más que un artefacto de régimen minoritario.

5.7. Atribución de características mediante Gradientes Integrados

Para abordar el requisito de interpretabilidad regulatoria destacado en la Sección 1.2, aplicamos Gradientes Integrados (Sundararajan et al., 2017) tanto al Conv1D-VAE como al Transformer, atribuyendo sus salidas a sensores de entrada individuales a lo largo de la trayectoria de prueba completa de un motor representativo. Los Gradientes Integrados calculan el gradiente promedio de la función objetivo a lo largo del camino rectilíneo desde una línea base cero hasta la entrada real, obteniendo una atribución que satisface los axiomas de completitud y sensibilidad para la atribución de características.

La Figura 2 muestra los resultados para la unidad 20 de FD001 ($\tau=P_{99}$, $p=3$, tiempo de adelanto = 15 ciclos). El panel (a) superpone la predicción del Transformer y su banda MC Dropout de $\pm 2\hat{\sigma}$ sobre la trayectoria de RUL verdadera, con

Cuadro 13: RMSE en C-MAPSS última ventana de prueba (límite RUL = 125). El mejor por conjunto de datos en negrita.

Referencia	Modelo	Revista	FD001	FD002	FD003	FD004
Li et al. (2018)	DCNN	RESS	12,61	22,36	12,64	23,31
Zhang et al. (2019)	BiLSTM	IEEE TIE	13,10	17,70	13,00	18,10
Chen et al. (2020)	BiLSTM-Atención	RESS	12,42	17,95	12,18	19,61
Zhu et al. (2021)	Transformer	IEEE TII	11,43	17,01	11,95	18,96
Mo et al. (2022)	BiLSTM-Multi-Att.	RESS	11,96	16,86	12,01	17,99
Song et al. (2023)	CNN-Transformer	IEEE TIM	11,15	16,12	11,42	17,45
Liu et al. (2023)	Transf. Doble Atención	RESS	11,27	15,78	11,40	17,10
Wang et al. (2024)	CNN-LSTM-Att. Híbrido	MSSP	11,04	15,92	11,38	16,95
Este trabajo	CNN+LSTM	—	13,58	14,08	15,30	16,44
Este trabajo	Transformer	—	14,28	14,01	14,05	17,14

el disparo del VAE (línea de puntos verde) y la zona crítica ($RUL \leq 30$, sombreado rojo) marcados. Los paneles (b) y (c) muestran $|GI|$ normalizado por sensor a lo largo del tiempo para el error de reconstrucción del ConvVAE y la predicción de RUL del Transformer, respectivamente.

Se desprenden tres observaciones. Primera, los sensores de temperatura T50 (s4), T30 (s3) y T24 (s2) muestran una atribución creciente en ambos paneles a medida que el motor se aproxima al fallo, consistente con la expectativa física de que las temperaturas de salida de la turbina y de entrada del compresor aumentan durante la degradación. Segunda, los sensores de presión y flujo Ps30 (s11) y P30 (s7) dominan el mapa de sensibilidad del ConvVAE en la ventana de disparo, explicando por qué se activa la compuerta: el VAE detecta una anomalía en la firma de presión más que una deriva térmica gradual. Tercera, la atribución del Transformer está más distribuida entre sensores en la fase sana pero se concentra en T50 y Ps30 en la zona crítica (sombreado rojo en el panel c), indicando que el modelo aprende implícitamente a aumentar el peso de las características ligadas a la degradación a medida que el RUL disminuye. Esta convergencia entre los patrones de atribución del VAE y del Transformer es consistente con un sistema en el que ambos componentes identifican de forma independiente la misma firma física de degradación, lo que apoya la validez operacional del diseño de compuerta jerárquica. Replicamos el análisis en los dos conjuntos de datos multi-régimen (FD002, unidad 7; FD004, unidad 40): los mismos sensores de temperatura y presión dominan las atribuciones de disparo y zona crítica, indicando que la firma de degradación identificada por la compuerta es estable a través de los regímenes de operación (los mapas de atribución correspondientes son producidos por el pipeline publicado).

6. Conclusiones y trabajo futuro

Hemos propuesto un sistema jerárquico de anomalías a RUL que combina un autoencoder variacional convolucional unidimensional, una métrica de zona crítica ($RMSE@crítico$) y una capa de compuerta cuantificada con métricas a nivel de sistema (tiempo de adelanto, TPR_{sys} , FAR_{sys}). Evaluado en los cuatro subconjuntos de datos C-MAPSS con $N_{semillas}=10$ ejecuciones deterministas, ICs bootstrap al 95 % y pruebas de Wilcoxon




Figura 2: Atribución por Gradientes Integrados para la unidad 20 de FD001 ($\tau=P_{99}$, persistencia $p=3$). (a) Predicción del Transformer ($\hat{\mu} \pm 2\sigma$ MC Dropout) frente al RUL verdadero; línea de puntos verde: disparo del VAE; sombreado rojo: zona crítica ($RUL \leq 30$). (b) $|GI|$ normalizado para el error de reconstrucción del ConvVAE: los sensores de temperatura y presión (T50, Ps30, P30) impulsan la señal de anomalía. (c) $|GI|$ normalizado para la predicción de RUL del Transformer: la atribución se concentra en T50 y Ps30 en la zona crítica, consistente con el patrón de sensibilidad del ConvVAE en el panel (b).

pareadas, el sistema proporciona 33–56 ciclos de tiempo de adelanto medio con un TPR en zona crítica del 80–100 %, y un RMSE absoluto en zona crítica de 5,4–10,1 ciclos. En los dos conjuntos de datos multi-régimen (FD002, FD004) el mejor regresor por conjunto de datos orquestado por la compuerta (Transformer y CNN+LSTM respectivamente) iguala o mejora el RMSE publicado de la última ventana de prueba; esto refleja la fortaleza de los regresores individuales más que de la capa de compuerta, cuya contribución es la señal operacional cuantificada (tiempo de adelanto, TPR_{sys} , FAR_{sys}) y no el RMSE bruto.

6.1. Limitaciones

Deben discutirse abiertamente dos limitaciones.

(i) La FAR a nivel de sistema es del 17–23 % en los conjuntos de datos multi-régimen. Esto es aceptable para un despliegue

de alarma con confirmación pero elevado para decisiones totalmente automatizadas. Un VAE condicional al régimen (un umbral por régimen) es la vía más probable para reducirlo.

(ii) La cobertura MC Dropout bruta se degrada en FD002 y FD004 ($\text{PICP} \leq 75\%$, $\text{ECE} \geq 0,11$). Esto se aborda mediante el escalado post-hoc de $\hat{\sigma}$ de la Sección 5.3, que restaura el PICP al 90–95 % y reduce el ECE por debajo de 0,07 (Tabla 8); una recalibración por régimen que evite el compromiso de factor único en datos multi-régimen queda para trabajo futuro.

6.2. Trabajo futuro

Cuatro direcciones se desprenden naturalmente de los presentes resultados: (i) VAEs condicionales al régimen para reducir FAR_{sys} en conjuntos de datos multi-régimen; (ii) recalibración post-hoc del MC Dropout; (iii) ensamblados $\text{CNN}+\text{LSTM}+\text{Transformer}$ ponderados por conjunto de datos, motivados por la complementariedad Wilcoxon de la Sección 5.2; (iv) mapas de atribución *condicionales al régimen* que, construyendo sobre el análisis de Gradientes Integrados por conjunto de datos ya reportado en la Sección 5.7, expondrían si diferentes puntos de operación activan diferentes sensores de degradación, un hallazgo directamente relevante para la aceptación regulatoria bajo la hoja de ruta de IA de la EASA (European Union Aviation Safety Agency, 2025). Una quinta dirección a más largo plazo es la integración de grandes modelos de series temporales preentrenados adaptados mediante ajuste de bajo rango, un enfoque emergente ya explorado en C-MAPSS (Chakravarty, 2025), que nuestra capa de compuerta podría orquestrar como regresor de alta fidelidad cuando se dispara. Finalmente, una variante exploratoria de DeepSurv basada en Cox evaluada durante el desarrollo no produjo un ranking de supervivencia útil a partir de características de la última ventana; su rediseño con un estimador de Breslow y representaciones multi-ventana es una dirección complementaria hacia la estimación probabilística del tiempo hasta el fallo.

Declaración de contribución de autoría CRediT

Rafael Pecino Bonilla: Conceptualización, Metodología, Software, Validación, Análisis formal, Investigación, Curación de datos, Escritura – borrador original, Visualización. **Jesús Gil:** Conceptualización, Supervisión, Escritura – revisión y edición.

Declaración de intereses en competencia

Los autores declaran que no tienen intereses financieros en competencia conocidos ni relaciones personales que puedan haber influido en el trabajo reportado en este artículo.

Disponibilidad de datos y código

El conjunto de datos C-MAPSS está disponible públicamente en el Repositorio de Datos de Pronóstico de la NASA (Saxena et al., 2008). El código fuente del pipeline, las semillas deterministas, los registros de ejecución y los hashes SHA-256 utilizados para producir cada tabla y figura de este artículo se publican en el repositorio del proyecto <https://github.com/rafapecino/TFM-AeroEngine-Anomaly-RUL-VAE-TFT> (SHA-256 del registro de ejecución: 662200fc9747). Las convenciones sobre la construcción de ventanas deslizantes, la agrupación de regímenes y el etiquetado de RUL por tramos fueron verificadas cruzadamente con líneas base de la comunidad de código abierto (Panara, 2023; Mo, 2022) para garantizar que los números reportados siguen el protocolo canónico de C-MAPSS y permanecen comparables con el estado del arte.

Agradecimientos

Los autores agradecen al Máster Universitario en Inteligencia Artificial (MUIA) de la Universidad Alfonso X El Sabio (UAX, Madrid, España) el entorno académico en el que se desarrolló este trabajo.

Referencias

- Asif, O., Haider, S.A., Naqvi, S.R., Zaki, J.F.W., Kwak, K.S., Islam, S.M.R., 2022. A deep learning model for remaining useful life prediction of aircraft turbofan engine on C-MAPSS dataset. *IEEE Access* 10, 95425–95440. doi:10.1109/ACCESS.2022.3203406.
- Azadeh, A., Asadzadeh, S., Salehi, N., Firoozi, M., 2015. Condition-based maintenance effectiveness for series-parallel power generation system – a combined markovian simulation model. *Reliability Engineering & System Safety* 142, 357–368.
- Babu, G.S., Zhao, P., Li, X.L., 2016. Deep convolutional neural network based regression approach for estimation of remaining useful life, in: *International Conference on Database Systems for Advanced Applications (DASFAA)*, Springer. pp. 214–228.
- Chakravarty, A.P., 2025. PredictEngineLife: RUL estimation of C-MAPSS turbofan engine using LLM4TS and low-rank adaptation. Master's project. San José State University. San José, CA, USA.
- Chen, J., Jing, H., Chang, Y., Liu, Q., 2020. Gated recurrent unit based recurrent neural network for remaining useful life prediction of nonlinear deterioration process. *Reliability Engineering & System Safety* 185, 372–382.
- Costa, N., Sánchez, L., 2022. Variational encoding approach for interpretable assessment of remaining useful life estimation. *Reliability Engineering & System Safety* 222, 108353.
- Ellefsen, A.L., Bjorlykhaug, E., Æsøy, V., Ushakov, S., Zhang, H., 2019. Remaining useful life predictions for turbofan engine degradation using semi-supervised deep architecture. *Reliability Engineering & System Safety* 183, 240–251.
- European Union Aviation Safety Agency, 2025. EASA AI Roadmap 2.0: a human-centric approach to AI in aviation. Technical Report. European Union Aviation Safety Agency (EASA). Cologne, Germany.
- Gal, Y., Ghahramani, Z., 2016. Dropout as a bayesian approximation: representing model uncertainty in deep learning, in: *International Conference on Machine Learning (ICML)*, pp. 1050–1059.
- Guo, C., Pleiss, G., Sun, Y., Weinberger, K.Q., 2017. On calibration of modern neural networks, in: *International Conference on Machine Learning (ICML)*, pp. 1321–1330.
- Heimes, F.O., 2008. Recurrent neural networks for remaining useful life estimation, in: *Proceedings of the International Conference on Prognostics and Health Management (PHM)*, IEEE. pp. 1–6.
- International Air Transport Association, 2026. Global outlook for air transport – December 2025/2026. Technical Report. International Air Transport Association (IATA). Geneva, Switzerland.
- International Civil Aviation Organization, 2026. ICAO business plan 2026–2028. Technical Report. International Civil Aviation Organization (ICAO). Montréal, Canada.
- Khelif, R., Chebel-Morello, B., Malinowski, S., Laajili, E., Fnaiech, F., Zerhouni, N., 2017. Direct remaining useful life estimation based on support vector regression. *IEEE Transactions on Industrial Electronics* 64, 2276–2285.
- Li, X., Ding, Q., Sun, J.Q., 2018. Remaining useful life estimation in prognostics using deep convolution neural networks. *Reliability Engineering & System Safety* 172, 1–11.
- Liu, L., Song, X., Zhou, Z., 2023. Aircraft engine remaining useful life estimation via a double attention-based data-driven architecture. *Reliability Engineering & System Safety* 221, 108330.
- Martínez-García, M., Zhang, Y., Wan, J., McGinty, J., 2019. Visually interpretable profile extraction with an autoencoder for health monitoring of industrial systems, in: *IEEE 4th International Conference on Advanced Robotics and Mechatronics (ICARM)*, pp. 649–654.
- Mo, H., 2022. N-CMAPSS_DL: deep-learning baselines on the N-CMAPSS dataset. https://github.com/mohyunho/N-CMAPSS_DL. Open-source benchmark, useful for cross-validation of pipeline conventions.
- Mo, Y., Wu, Q., Li, X., Huang, B., 2022. Remaining useful life estimation via transformer encoder enhanced by a gated convolutional unit. *Reliability Engineering & System Safety* 220, 108289.
- Panara, U., 2023. Remaining useful life prediction for turbofan engines (C-MAPSS). <https://github.com/UtkarshPanara/Remaining-Useful-Life-Prediction-for-Turbofan-Engines>. Open-source implementation. Used as community baseline for sanity checks.
- Saxena, A., Goebel, K., Simon, D., Eklund, N., 2008. Damage propagation modeling for aircraft engine run-to-failure simulation, in: *Proceedings of the International Conference on Prognostics and Health Management (PHM)*, IEEE. pp. 1–9.
- Si, X.S., Wang, W., Hu, C.H., Zhou, D.H., 2011. Remaining useful life estimation – a review on the statistical data driven approaches. *European Journal of Operational Research* 213, 1–14.
- Song, Y., Gao, S., Li, Y., Jia, L., Li, Q., Pang, F., 2023. Distributional cnn-transformer-based regression for remaining useful life estimation. *IEEE Transactions on Instrumentation and Measurement* 72, 3503312.
- Sundararajan, M., Taly, A., Yan, Q., 2017. Axiomatic attribution for deep networks, in: *International Conference on Machine Learning (ICML)*, pp. 3319–3328.
- Tian, Z., 2012. An artificial neural network method for remaining useful life prediction of equipment subject to condition monitoring. *Journal of Intelligent Manufacturing* 23, 227–237.
- Wang, H., Li, D., Li, D., Liu, C., Yang, X., Zhu, G., 2024. Remaining useful life prediction of aircraft turbofan engine based on a hybrid cnn-lstm-attention network. *Mechanical Systems and Signal Processing* 209, 111120.
- Xiang, S., Qin, Y., Luo, J., Pu, H., Tang, B., 2021. Multicellular lstm-based deep learning model for aero-engine remaining useful life prediction. *Reliability Engineering & System Safety* 216, 107927.
- Xu, Z., Saleh, J.H., 2021. Machine learning for reliability engineering and safety applications: review of current status and future opportunities. *Reliability Engineering & System Safety* 211, 107530.
- Zhang, J., Wang, P., Yan, R., Gao, R.X., 2019. Long short-term memory for ma-

- chine remaining life prediction. *IEEE Transactions on Industrial Electronics* 66, 600–608.
- Zheng, S., Ristovski, K., Farahat, A., Gupta, C., 2017. Long short-term memory network for remaining useful life estimation, in: *IEEE International Conference on Prognostics and Health Management (ICPHM)*, pp. 88–95.
- Zhu, Y., Wu, J., Wu, J., Liu, S., 2021. Dimensionality reduce-based machine remaining useful life prediction with attention-based deep learning approach. *IEEE Transactions on Industrial Informatics* 17, 7997–8007.